Gestión del conocimiento de las organizaciones. Práctica

Sistemas de recomendación -Modelos basados en el conocimiento -

Autor : Manuel Ramón Regalado Peraza. Correo : <u>alu0100283433@ull.edu.es</u>

Índice de usuario

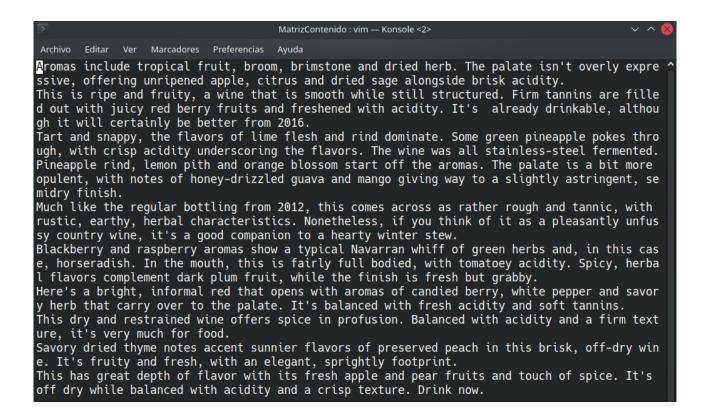
- Análisis de varios documentos de ejemplo con la aplicación construida	1
• Análisis de documents01.txt	
■ Análisis de documents01.txt	
• Análisis de d1.txt	
■ Análisis de d2.txt	
- Conclusiones	

- Análisis de varios documentos de ejemplo con la aplicación construida.

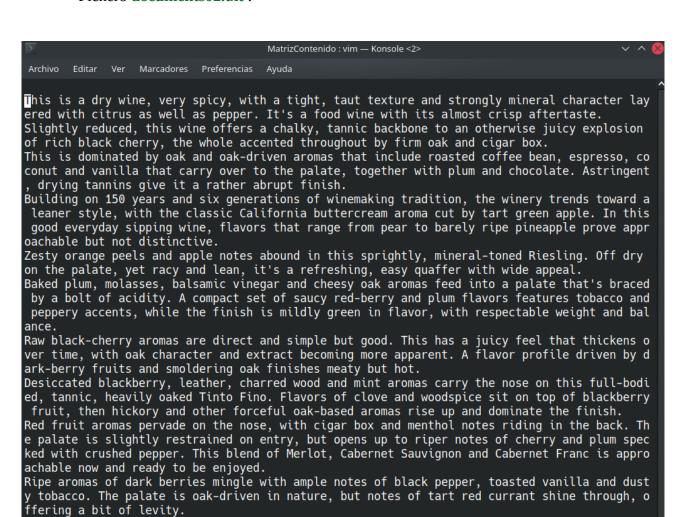
Empezaremos indicando que se han usado los ficheros de ejemplo proporcionados por el profesor para esta actividad en el repositorio de GitHub :

https://github.com/cexposit/ull-gco/tree/main/examples-documents

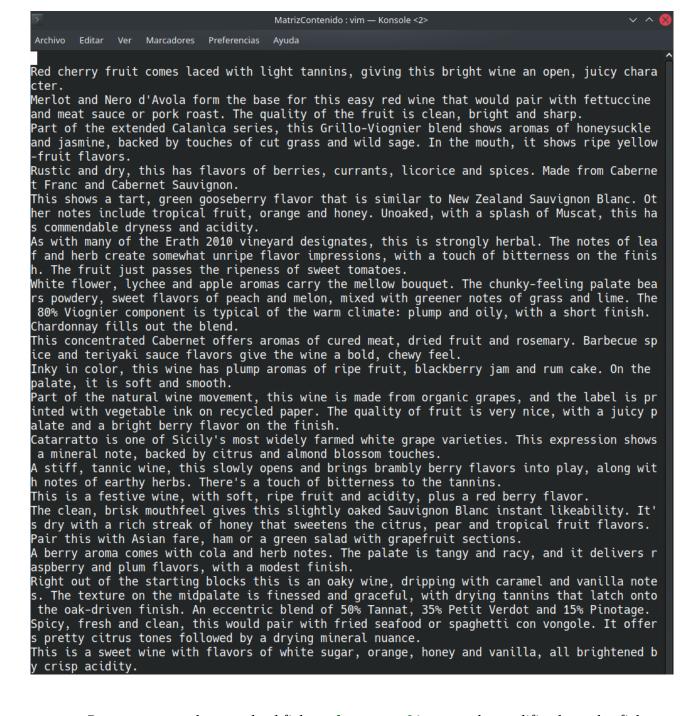
- Tenemos 3 ejemplos, en inglés, sobre valoraciones de distintos tipos de vinos. Los contenidos de cada fichero incluyen distintos tipos de *documentos*, líneas de texto seguidas hasta encontrar el primer salto de línea, que conforman cada una de las valoraciones mencionadas anteriormente :
 - Fichero documents01.txt:



- Fichero documents02.txt :



- Fichero documents03.txt :



Por otra parte se ha tomado el fichero documents01.txt y se ha modificado en dos ficheros (d1.txt y d2.txt) para usarse como ejemplos de *juguete* y que se aprecie un poco mejor los resultados.

- Fichero **d1.txt**. Sólo tiene dos documentos exactamente iguales salvo que ambos difieren en una palabra en cada una (**tropic/tropical**) :

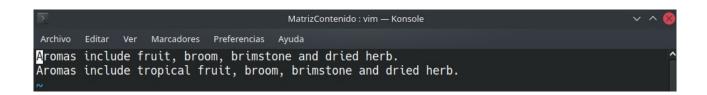
```
MatrizContenido:vim — Konsole <2> ∨ ∧ ⊗
Archivo Editar Ver Marcadores Preferencias Ayuda

Aromas include tropic fruit, broom, brimstone and dried herb.

Aromas include tropical fruit, broom, brimstone and dried herb.

~
```

- Fichero **d2.txt**. También dos documentos iguales salvo que se ha eliminado una palabra en el primer documento (*tropical*) :



Descritos los ficheros a usar, haremos algunos análisis.

Análisis de documents01.txt

• Ejecutamos el programa desde la terminal, haciendo un **\$** ./CalcSim documents01.txt y vemos el resultado de los cálculos de la similaridad coseno en la matriz del final del análisis:

<u>Nota</u>: La matriz es simétrica, esto quiere decir que los datos por encima de la diagonal son los mismos que los que están por debajo de la diagonal, sólo están en posiciones en los que los documentos que representan las filas representan los de las columnas y viceversa al buscar el mismo valor por encima o debajo de la diagonal. También fijarse que como en la diagonal se está haciendo la similitud con el mismo documento, su resultado es un similitud perfecta, un 1 (esto no nos servirá para nada en los análisis, por cierto). Los valores de la matriz son valores reales que irán desde el 0 (0% de similaridad de términos entre dos documentos) al 1 (100% de similaridad de términos entre dos documentos significa que ambos tienen los mismos términos y que estos aparecen las mismas veces en ellos, mientras que un 0 significa que no tienen ni un sólo término en común entre ellos.

- Apreciamos los datos que destacan, resaltados en colores :
- Los mismos colores pertenecen a la misma celda (además se resaltó con el mismo color a cuáles documentos en la fila y columna pertenece)
- Los valores en verde y en azul pertenecen a los valores máximos de similitud/similaridad posibles, que son entre el documento **8º** y el **10º** (ó entre el **10º** y el **8º**, como queramos verlo). El valor es **0,338062**, es decir, aproximadamente un **33,8062%** de similitud de términos entre ellos. Aproximadamente un tercio de los términos del documento **8** aparecen en el documento **10**.

```
Documento 8 :
                                                                         Documento 10 :
                                                                         |1|
|2|
             acidity, (1, 0.154902, 0.154902)}
                                                                                      acidity, (1, 0.154902, 0.154902)}
             balanced, (1, 0.522879, 0.522879)}
dry, (1, 0.69897, 0.69897)}
firm, (1, 0.69897, 0.69897)}
                                                                                      apple, (1, 0.69897, 0.69897)}
balanced, (1, 0.522879, 0.522879)}
                                                                          3
                                                                                      crisp, (1, 0.69897, 0.69897)}
                                                                          4
             food, (1, 1, 1)}
                                                                          j 5 j
                                                                                      depth, (1, 1, 1)}
drink, (1, 1, 1)}
             for, (1, 1, 1)}
it's, (1, 0.221849, 0.221849)}
6
                                                                          6
                                                                                      dry, (1, 0.69897, 0.69897)}
flavor, (1, 1, 1)}
fresh, (1, 0.39794, 0.39794)}
[ fruits, (1, 0.69897, 0.69897)}
                                                                          7
             much, (1, 0.69897, 0.69897)} offers, (1, 1, 1)}
                                                                          8
|8|
            offers, (1, 1, 1)}
{ profusion, (1, 1, 1)}
{ restrained, (1, 1, 1)}
{ spice, (1, 0.69897, 0.69897)}
{ texture, (1, 0.69897, 0.69897)}
                                                                          9 į
                                                                          10|
10
                                                                                        great, (1, 1, 1)}
|11|
                                                                          11
                                                                                        has, (1, 1, 1)}
it's, (1, 0.221849, 0.221849)}
                                                                          12
|12|
                                                                          13
|13|
               very, (1, 1, 1)}
                                                                          14
                                                                                        its, (1, 1, 1)}
|14|
              wine, (1, 0.30103, 0.30103)}
                                                                          15
                                                                                        now, (1, 1, 1)}
                                                                                        off, (1, 0.69897, 0.69897)}
                                                                          16
                                                                          17
                                                                                        pear, (1, 1, 1)}
                                                                                        spice, (1, 0.69897, 0.69897)}
                                                                          18
                                                                                        texture, (1, 0.69897, 0.69897)}
                                                                          19
                                                                                        touch, (1, 1, 1)}
                                                                          20
                                                                          21
                                                                                                   (1, 0.522879, 0.522879)}
```

- Los valores en rojo pertenece al cálculo de la similaridad que da el mínimo valor posible de similitud : el **0** (un **0%**). Se eligió un valor al azar, que representa aquí a los documentos **5** y **4**. Los términos de ambos documentos se muestra a continuación :

```
Documento 5 :
Documento 4 :
                                                     |1|
                                                               2012, (1, 1, 1)}
          aromas, (1, 0.39794, 0.39794)}
                                                      |2|
                                                                across,
                                                                         (1, 1, 1)
2
          astringent, (1, 1, 1)}
                                                      3|
                                                               bottling, (1, 1, 1)}
3
          bit, (1, 1, 1)}
                                                               characteristics, (1, 1, 1)}
comes, (1, 1, 1)}
4
          blossom, (1, 1, 1)}
                                                      4
          finish, (1, 0.69897, 0.69897)}
                                                      5
5
                                                               companion, (1, 1, 1)}
6
                                                      6
          giving, (1, 1, 1)}
                                                               country, (1, 1, 1)}
                                                      7
          guava, (1, 1, 1)}
                                                               earthy, (1, 1, 1)}
          honey-drizzled, (1, 1, 1)}
                                                      8
                                                      9 j
                                                               good, (1, 1, 1)}
9
          is, (1, 0.522879, 0.522879)}
                                                                 hearty, (1, 1, 1)}
                                                      10|
|10|
           lemon, (1, 1, 1)}
                                                                 herbal, (1, 0.69897, 0.69897)}
                                                      111
111
           mango, (1, 1,
           more, (1, 1, 1)}
notes, (1, 0.69897, 0.69897)}
off, (1, 0.69897, 0.69897)}
opulent, (1, 1, 1)}
                                                                 it, (1, 0.69897, 0.69897)}
 12
                                                     1121
                                                                 it's, (1, 0.221849, 0.221849)}
                                                     |13|
 13|
                                                     |14|
                                                                 like, (1, 1, 1)}
 141
                                                                 much, (1, 0.69897, 0.69897)}
                                                      15
 15|
                                                                 nonetheless, (1, 1, 1)}
pleasantly, (1, 1, 1)}
rather, (1, 1, 1)}
           orange, (1, 1, 1)}
palate, (1, 0.522879, 0.522879)}
                                                      16
16
                                                      |17|
17
           pineapple, (1, 0.69897, 0.69897)}
                                                      |18|
18
                                                      |19|
                                                                 regular, (1, 1, 1)}
191
           pith, (1, 1, 1)}
            rind, (1, 0.69897, 0.69897)}
                                                      20
                                                                 rough, (1, 1, 1)}
201
                                                      21
                                                                 rustic, (1,
            semidry, (1, 1, 1)}
21
                                                                 stew, (1,
                                                     1221
           slightly, (1, 1, 1)}
start, (1, 1, 1)}
22
                                                     1231
                                                                 tannic, (1, 1, 1)}
 23|
                                                      1241
                                                                 think, (1, 1, 1)}
24
           way, (1, 1, 1)}
                                                                 unfussy, (1, 1, 1)}
                                                      |25|
                                                                 wine, (1, 0.30103, 0.30103)}
                                                      26
                                                      27
                                                                 winter, (1,
                                                      28
                                                                 you, (1, 1,
```

Si comparamos todos los términos, no existe ni uno que aparezca en ambos documentos y por ello tenemos una similaridad del 0%.

• Análisis de d1.txt

• En este primer ejemplo de juguete los resultados son :

```
Aromas include tropic fruit, broom, brimstone and dried herb.
Aromas include tropical fruit, broom, brimstone and dried herb.
Documento 1 :
         { aromas, (1, 0, 0)}
           brimstone, (1, 0, 0)}
        { brom, (1, 0, 0)}
{ dried, (1, 0, 0)}
{ fruit, (1, 0, 0)}
{ herb, (1, 0, 0)}
{ include, (1, 0, 0)}
{ tropic, (1, 0.30103, 0.30103)}
Documento 2 :
         { aromas, (1, 0, 0)}
           brimstone, (1, 0, 0)}
         { broom, (1, 0, 0)}
         { dried, (1, 0, 0)}
           fruit, (1, 0, 0)}
herb, (1, 0, 0)}
include, (1, 0, 0)}
tropical, (1, 0.30103, 0.30103)}
 - Datos de similaridades coseno -
         (D1) (D2)
        1 || 0.875
(D1)
          0.875 || 1 |
mrrp@portatil:~/Escritorio/MatrizContenido$ ./CalcSim d1.txt
```

- Se aprecia que como cada documento tienen tienen los mismos términos salvo uno en cada uno de ellos (términos **tropic** y **tropical**), se muestra que ambos documentos son iguales salvo en (⅓ = 0,125 → Un 12,5%). Es decir, que son similares entre ellos en un 87,5% (un 0,875)

- Análisis de d2.txt

• En este segundo ejemplo de juguete los resultados son :

```
Aromas include fruit, broom, brimstone and dried herb.
Aromas include tropical fruit, broom, brimstone and dried herb.
Documento 1 :
        { aromas, (1, 0, 0)}
          brimstone, (1, 0, broom, (1, 0, 0)}
          dried, (1, 0, 0)}
          fruit, (1, 0, 0)}
herb, (1, 0, 0)}
include, (1, 0, 0)}
Documento 2 :
        { aromas, (1, 0, 0)}
        { brimstone, (1, 0, 
{ broom, (1, 0, 0)} 
{ dried, (1, 0, 0)}
           fruit, (1, 0, 0)}
           herb, (1, 0, 0)}
           include, (1, 0, 0)}
tropical, (1, 0.30103, 0.30103)}
 - Datos de similaridades coseno -
        (D1) (D2)
       | 1 || 0.935414
(D1)
         0.935414 || 1 |
mrrp@portatil:~/Escritorio/MatrizContenido$ ./CalcSim d2.txt
```

- Vemos aquí que aumenta la similaridad respecto al ejemplo de *juguete* anterior porque hemos quitado el el documento 1 una palabra que no aparecía en el documento 2, esto ocasiona que ahora estemos en una situación en la sólo haya un término que esté en un sólo documento, en vez de dos términos como en **d1.txt**. Todo lo anterior se traduce en una mayor similaridad entre documentos, subiendo de un **87,5%** a un **93,5414%**.

- Conclusiones.

1º)Hemos visto que con esta herramienta/aplicación podremos analizar y calcular cuán similares pares de documentos son entre sí, a nivel de términos y veces que aparecen en cada uno de ellos.

2º)Cuantos más términos/palabras en común tengan dos documentos más alto será su simililaridad. Y al revés, cuantos menos tengan en común más bajo será esta similaridad.

- 3°)También hemos deducido que hay más similitud entre pares de documentos cuanto más términos coincidan entre ellos y menos términos diferentes entre ellos aparezcan.
- 4°)Las utilidades de este tipo de cálculos de similaridad de términos en contenidos es una herramienta útil para poder recomendar obras relativamente iguales a los usuarios que consuman contenidos en una plataforma determinada.